Caracterización reproducible del paisaje mutacional del cáncer cervicouterino

Proyecto 2: Variantes somáticas, genes drivers y firmas mutacionales en cáncer

Pregunta biomédica

¿Qué diferencias presenta el paisaje mutacional del cáncer cervicouterino según el grado tumoral (G2 vs G3) y el subtipo histológico (carcinoma escamoso vs adenocarcinoma), en términos de carga mutacional y genes recurrentemente alterados?

1. Contexto y propósito

El cáncer cervicouterino presenta heterogeneidad clínica e histológica y, en paralelo, variabilidad en el número y tipo de mutaciones somáticas de cada tumor. El proyecto combina una rama técnica, destinada a demostrar un procesamiento reproducible desde FASTQ, con una rama de cohorte que posteriormente permitirá estudiar patrones mutacionales y variables clínicas.

Objetivo general

Caracterizar de forma reproducible el paisaje mutacional del cáncer cervicouterino mediante un workflow en Nextflow DSL2 para el procesamiento de variantes somáticas y un análisis de cohorte basado en datos públicos de TCGA-CESC.

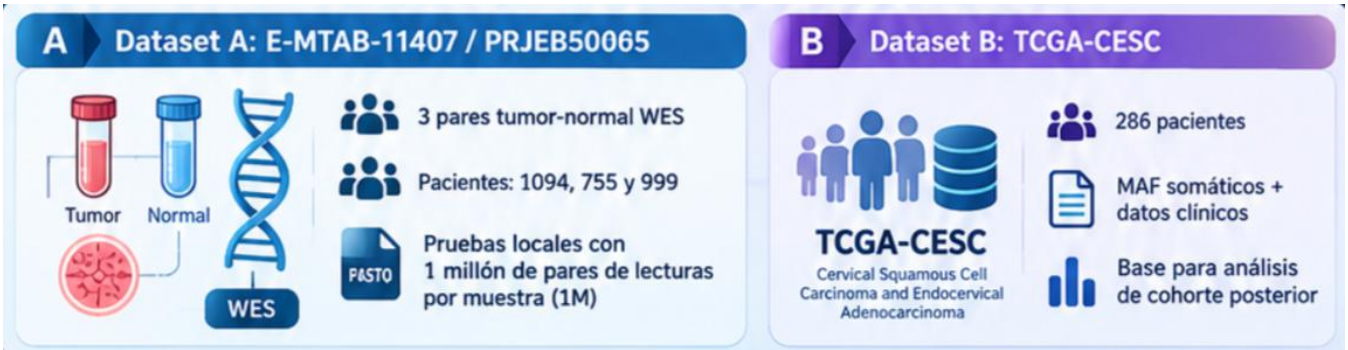
Alcance de la Entrega Nº2

Esta entrega se concentra en la implementación y validación técnica del pipeline tumor-normal. Se completa el flujo desde FASTQ hasta VCF anotado con SnpEff, se documentan ambientes y parámetros reproducibles, se ejecutan pruebas con tres pares tumor-normal y se conservan reportes de Nextflow para trazabilidad.

Resultado de esta Entrega

Pipeline Nextflow DSL2 funcional + ambientes reproducibles + tres ejecuciones de prueba de 1M + VCF filtrados/anotados + report, timeline, trace y DAG.

2. Conjuntos de datos seleccionados



Dataset A - E-MTAB-11407 / PRJEB50605

Subconjunto WES de carcinoma escamoso cervicouterino con muestras tumor-normal pareadas. Este dataset se utiliza para desarrollar y validar el pipeline técnico.

Paciente	Tumor	Normal	Uso en la entrega
1094	ERR8314271	ERR8314261	Prueba pipeline 1M
755	ERR8314276	ERR8314265	Prueba pipeline 1M
999	ERR8314284	ERR8314269	Prueba pipeline 1M

Cada paciente aporta una muestra tumoral y una muestra normal; cada muestra dispone de FASTQ paired-end R1/R2. En total corresponden a 6 muestras y 12 FASTQ. Para la validación local se generaron subconjuntos reproducibles de 1 millón de pares de lecturas por muestra (1M).

Genoma de referencia

Para el procesamiento del Dataset A, las lecturas FASTQ de las muestras tumor-normal se alinean contra el genoma de referencia humano GRCh38 mediante BWA-MEM2. Para este proceso se prepararon Homo_sapiens_assembly38.fasta, su índice .fai, el diccionario .dict y los índices requeridos por BWA-MEM2. Debido a su tamaño, estos archivos de referencia no se almacenan en GitHub.

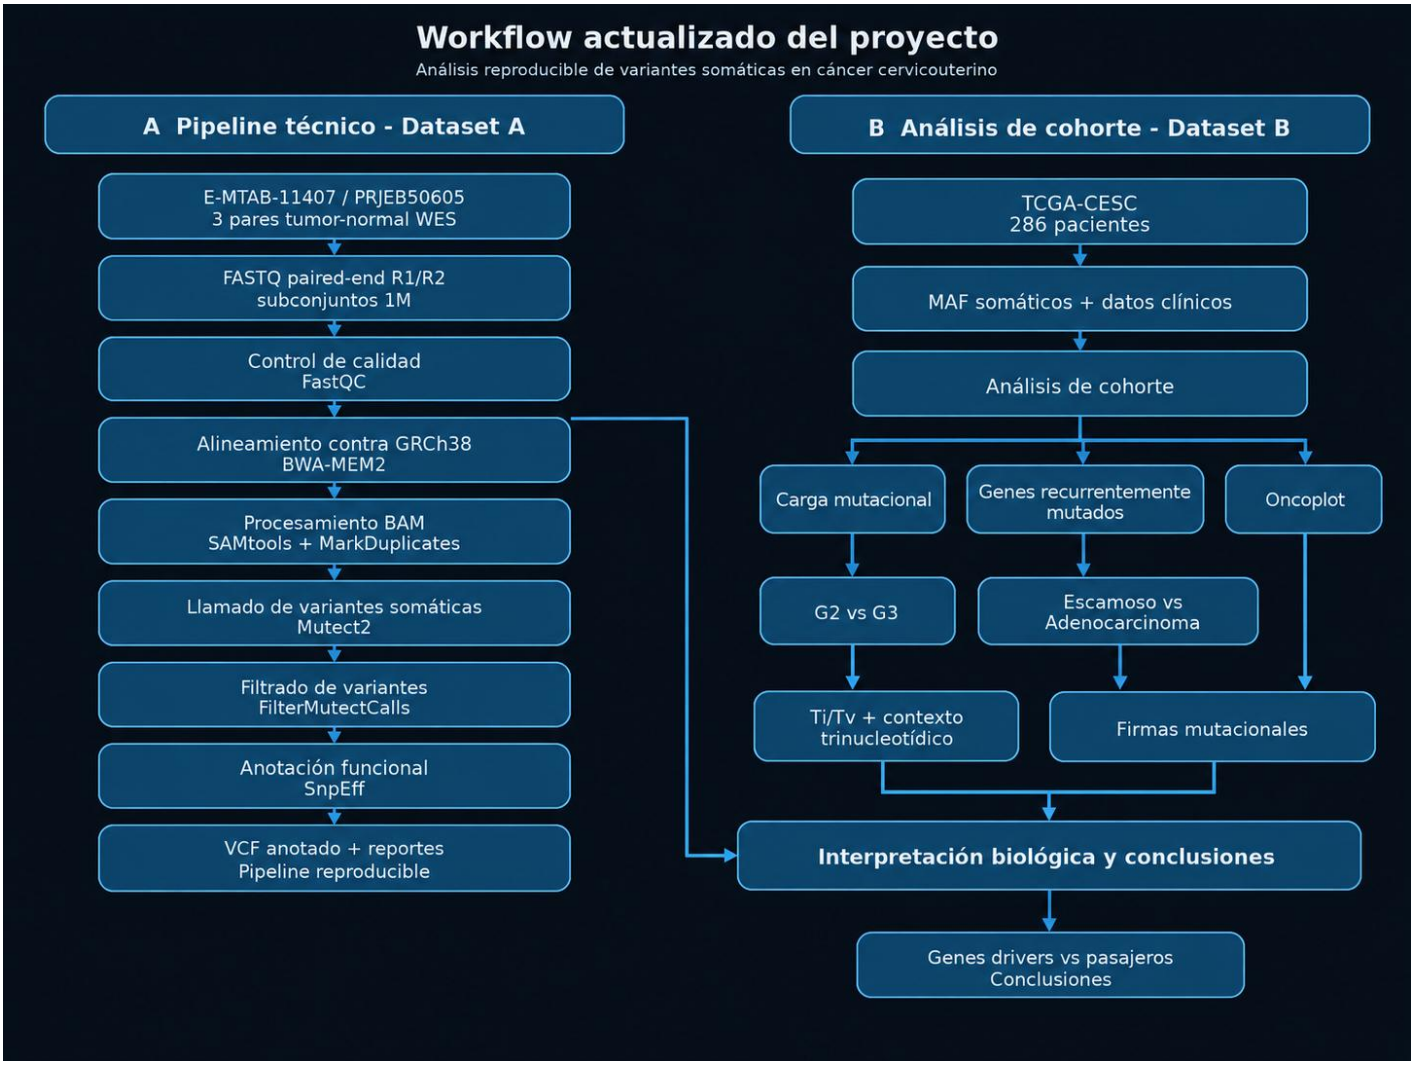
Dataset B - TCGA-CESC

Cohorte pública obtenida desde NCI Genomic Data Commons (GDC). Se reserva para el análisis biológico de cohorte en la etapa siguiente del proyecto.

Componente	Resultado preparado
Casos con MAF	286 pacientes únicos
Archivos descargados	287 MAF; se utilizará 1 MAF por paciente
Grado tumoral	G2: 126 | G3: 111
Histología	Escamoso: 236 | Adenocarcinoma: 46 | Otros: 4
Uso posterior	Carga mutacional, genes recurrentes, oncoplot, firmas y comparaciones clínicas

3. Workflow actualizado del proyecto

El proyecto mantiene dos ramas complementarias. En la Entrega 2 se implementa la rama técnica completa desde FASTQ hasta anotación funcional; la rama TCGA-CESC queda preparada para el análisis de cohorte posterior.





4. Implementación reproducible del pipeline

El workflow está implementado en Nextflow DSL2. Los procesos principales definidos en `main.nf` son FASTQC, BWA_MEM2, SAMTOOLS_INDEX, MARK_DUPLICATES, MUTECT2, FILTER_MUTECT_CALLS y SNPEFF.

Software y ambientes

Herramienta	Versión / ambiente	Función principal
Nextflow	26.04.6	Orquestación DSL2
FastQC	0.12.1	Control de calidad
BWA-MEM2	2.3	Alineamiento GRCh38
SAMtools	1.24	Ordenamiento e indexación BAM
seqtk	1.5	Submuestreo reproducible 1M
GATK	4.6.2.0	MarkDuplicates, Mutect2 y filtrado
Picard	3.4.0	Soporte MarkDuplicates
SnpEff	5.4.0c	Anotación funcional

Archivos de ambiente

- `conf/environment_nextflow.yml`: Nextflow, FastQC, BWA-MEM2, SAMtools y seqtk.
- `conf/environment_gatk4.yml`: GATK 4.
- `conf/environment_snpeff.yml`: SnpEff 5.4.0c.

La base de anotación utilizada es `GRCh38.mane.1.5.ensembl`.

Parámetros principales

```
samplesheet: "samplesheet/cervical_wes_pipeline_samplesheet.csv"
outdir: "results"
reference: "data/reference/grch38/Homo_sapiens_assembly38.fasta"
reference_prefix: "data/reference/grch38/Homo_sapiens_assembly38"
interval: null
snpeff_db: "GRCh38.mane.1.5.ensembl"
snpeff_heap: "8g"
```

Creación de ambientes y base SnpEff

```
micromamba create -f conf/environment_nextflow.yml
micromamba create -f conf/environment_gatk4.yml
micromamba create -f conf/environment_snpeff.yml
micromamba run -n snpeff snpEff download GRCh38.mane.1.5.ensembl
```

5. Ejecución de prueba y organización de resultados

Se utilizaron samplesheets independientes para los tres subconjuntos de 1M, lo que permite repetir cada ejecución sin modificar los FASTQ originales.

- `samplesheet/cervical_wes_1094_1M_samplesheet.csv`
- `samplesheet/cervical_wes_755_1M_samplesheet.csv`
- `samplesheet/cervical_wes_999_1M_samplesheet.csv`

Ejemplo de ejecución

```
nextflow run main.nf \
  -params-file conf/params.yaml \
  --samplesheet samplesheet/cervical_wes_1094_1M_samplesheet.csv \
  --outdir results/test_1094_1M \
  --interval chr1,chr2,...,chr22,chrX,chrY \
  -with-report results/test_1094_1M/nextflow_reports/report.html \
  -with-timeline results/test_1094_1M/nextflow_reports/timeline.html \
  -with-trace results/test_1094_1M/nextflow_reports/trace.txt \
  -with-dag results/test_1094_1M/nextflow_reports/dag.html
```

Estructura de salida por paciente

Los reportes de Nextflow documentan procesos ejecutados, tiempos, consumo de recursos y dependencias del workflow. Los VCF anotados finales quedan en `annotation/`, mientras que los archivos derivados para análisis posterior se almacenan en `results/downstream/`.



Archivos finales anotados

- `results/test_1094_1M/annotation/1094.snpeff.vcf`
- `results/test_755_1M/annotation/755.snpeff.vcf`
- `results/test_999_1M/annotation/999.snpeff.vcf`

Control de errores y validación técnica

Durante las ejecuciones se verificó la correcta lectura de los FASTQ, la generación de los archivos BAM e índices, la producción de los VCF sin filtrar / filtrados y la presencia de la anotación funcional ANN de SnpEff en los VCF finales. Los archivos report.html, timeline.html, trace.txt y dag.html permiten revisar el estado de los procesos, tiempos de ejecución, consumo de recursos y dependencias del workflow, facilitando la identificación de tareas fallidas o incompletas.

6. Resultados de validación de la Entrega Nº2

Las tres ejecuciones de 1M produjeron VCF filtrados y anotados. Las variantes siguientes corresponden a llamadas PASS de FilterMutectCalls presentes en los VCF finales; no deben interpretarse todavía como carga mutacional real del tumor.

Paciente	PASS	MODERATE	LOW	MODIFIER
1094	6	0	1	5
755	15	1	8	6
999	34	19	8	7
Total	55	20	17	18

Resumen funcional

- Se identificaron 55 variantes PASS en total en los tres subconjuntos de prueba.
- SnpEff clasificó 20 variantes como MODERATE, 17 como LOW y 18 como MODIFIER; no se observaron variantes HIGH en estos subconjuntos.
- Entre las consecuencias MODERATE se observaron variantes missense y deleciones in-frame. La categoría MODERATE representa una consecuencia funcional predicha y no implica por sí sola patogenicidad ni condición de gen driver.

Archivos derivados

- `results/downstream/pass_variants_1M.csv`: tabla conjunta de 55 variantes PASS.
- `results/downstream/moderate_variants_1M.csv`: variantes de impacto MODERATE.
- `results/downstream/moderate_variants_evidence_1M.csv`: evidencia de lectura (DP, AD, VAF y TLOD).
- `results/downstream/moderate_variants_ranked_1M.csv`: ordenamiento técnico por evidencia.

Ejemplos de evidencia técnica

Paciente	Gen	Cambio	TLOD	ALT normal	ALT tumor	VAF tumor
755	HRNR	p.Gln519Pro	28.00	0	8	0.400
999	ZNF804B	p.Ala1264Glu	19.78	0	6	0.462
999	KRTAP10-6	p.Val159Ile	11.78	0	4	0.138

Estas observaciones se utilizan únicamente como control técnico de las llamadas obtenidas con los subconjuntos de 1M. La interpretación biológica definitiva se realizará con la cohorte TCGA-CESC.

7. Reproducibilidad, limitaciones y próximos pasos

Reproducibilidad

Los archivos genómicos pesados (FASTQ, BAM, referencia e índices) no se almacenan en GitHub. Se conservan código, parámetros, ambientes, manifests, metadata, samplesheets, URLs de descarga, VCF anotados de prueba, tablas pequeñas y reportes de ejecución.

Repositorio GitHub

https://github.com/5leyla5/proyecto_cesc

Limitaciones de esta etapa

- Los subconjuntos de 1M no representan la profundidad completa del WES original; por ello el número de variantes detectadas no corresponde a una estimación definitiva de carga mutacional.
- Una variante PASS supera los filtros utilizados en esta ejecución, pero no constituye validación experimental.
- El workflow actual de Mutect2 no incorpora todavía Panel of Normals, recurso poblacional de variantes germinales ni estimación de contaminación.
- La base MANE utilizada por SnpEff prioriza transcritos de referencia y puede diferir de una anotación basada en todos los transcritos Ensembl.

Próximo paso

Con la rama técnica validada, la siguiente etapa utilizará el Dataset B (TCGA-CESC) para caracterizar la cohorte, estimar carga mutacional, identificar genes recurrentemente alterados, generar oncoplots, evaluar Ti/Tv y contexto trinucleotídico, explorar firmas mutacionales y comparar G2 vs G3 y carcinoma escamoso vs adenocarcinoma.

Procedencia de los datos

- BioStudies / ArrayExpress E-MTAB-11407: https://www.ebi.ac.uk/biostudies/arrayexpress/studies/E-MTAB-11407
- ENA PRJEB50605: https://www.ebi.ac.uk/ena/browser/view/PRJEB50605
- Publicación asociada: https://pmc.ncbi.nlm.nih.gov/articles/PMC5102491/
- NCI GDC TCGA-CESC: https://portal.gdc.cancer.gov/projects/TCGA-CESC
- GDC Data Portal: https://portal.gdc.cancer.gov/