Caracterización reproducible del paisaje mutacional del cancer cervicouterino

Proyecto 2: Variantes somáticas, genes drivers y firmas mutacionales en cancer

Pregunta biomédica

¿Qué diferencias presenta el paisaje mutacional del cáncer cervicouterino según el grado tumoral (G2 vs G3) y el subtipo histológico (carcinoma escamoso vs adenocarcinoma), en términos de carga mutacional y genes recurrentemente alterados?

1. Contexto y propósito

El cáncer cervicouterino presenta heterogeneidad clínica e histológica. Esta variabilidad puede acompañarse de diferencias en el número y tipo de mutaciones somáticas presentes en cada tumor. El proyecto busca integrar procesamiento bioinformático reproducible con un análisis de cohorte que permita describir el paisaje mutacional y explorar diferencias asociadas al grado tumoral y al subtipo histológico.

Objetivo general

Caracterizar de forma reproducible el paisaje mutacional del cáncer cervicouterino mediante un workflow en Nextflow DSL2 para el procesamiento de variantes somáticas y un análisis de cohorte basado en datos públicos de TCGA-CESC.

Decisión metodológica principal

Se utilizarán dos conjuntos de datos complementarios: un conjunto pequeño de pares tumor-normal para demostrar el pipeline desde FASTQ y una cohorte amplia con archivos MAF públicos para realizar el análisis biológico y las comparaciones clínicas. Esta estrategia sigue el enfoque sugerido para el Proyecto 2.

Resultado esperado de esta entrega: pregunta definida + datasets seleccionados + workflow propuesto + samplesheets + repositorio inicial de GitHub con desarrollo parcial en Nextflow.

2. Conjuntos de datos seleccionados

Dataset A - Cohorte TCGA-CESC

Fuente: NCI Genomic Data Commons (GDC). Proyecto: TCGA-CESC. Tipo de dato: Masked Somatic Mutation. Formato: MAF. Estrategia: WXS. Acceso: abierto.

Componente	Resultado preparado
Casos con MAF	286 pacientes únicos
Archivos descargados	287 MAF; se selecciona 1 MAF por paciente para análisis
Grado tumoral	G2: 126 | G3: 111
Histología	Escamoso: 236 | Adenocarcinoma: 46 | Otros: 4
Uso en el proyecto	Análisis de cohorte, carga mutacional, genes recurrentes, oncoplot y firmas

Dataset B - WES tumor-normal de cáncer cervicouterino

Estudio: E-MTAB-11407 / PRJEB50605. Tipo tumoral: carcinoma escamoso cervicouterino. Plataforma: Illumina. Layout: paired-end. Se seleccionaron tres pacientes para mantener un conjunto pequeño y manejable para la implementación técnica del workflow.

Paciente	Tumor	Normal	Criterio didáctico
1094	ERR8314271	ERR8314261	Carga mutacional alta
755	ERR8314276	ERR8314265	Carga mutacional intermedia
999	ERR8314284	ERR8314269	Carga mutacional baja

Cada paciente aporta tumor y normal pareado; cada muestra posee R1 y R2. En total se utilizarán 6 muestras y 12 FASTQ. Los 12 archivos fueron verificados mediante gzip -t.

Genoma de referencia

Se preparó GRCh38 con los archivos Homo_sapiens_assembly38.fasta, .fasta.fai y .dict. El índice específico de BWA-MEM2 se generará durante el desarrollo del pipeline.

Procedencia de los datos

GDC TCGA-CESC: https://portal.gdc.cancer.gov/projects/TCGA-CESC
BioStudies E-MTAB-11407: https://www.ebi.ac.uk/biostudies/arrayexpress/studies/E-MTAB-11407
ENA PRJEB50605: https://www.ebi.ac.uk/ena/browser/view/PRJEB50605
Publicación asociada: https://pmc.ncbi.nlm.nih.gov/articles/PMC5102491/

3. Diagrama del workflow propuesto

El proyecto tiene dos ramas complementarias: la rama técnica demuestra el procesamiento desde FASTQ; la rama de cohorte amplía el análisis utilizando MAF somáticos y metadata clínica.



Rama técnica: FASTQ R1/R2 -> FastQC -> BWA-MEM2 + GRCh38 -> samtools -> Mutect2 -> filtrado -> VCF anotado. Rama de cohorte: TCGA-CESC -> MAF + clínica -> carga mutacional, genes recurrentes, oncoplot, Ti/Tv, contexto trinucleotídico y firmas -> comparaciones G2/G3 y escamoso/adenocarcinoma -> interpretación biológica.

4. Samplesheets y detalle de las muestras

Los samplesheets conectan de forma reproducible los archivos genómicos con cada paciente y sus variables clínicas. Se mantienen dos archivos principales porque los datasets cumplen funciones distintas.

Samplesheet de cohorte - TCGA-CESC

- file_id
- file_name
- case_id
- tumor_sample
- normal_sample
- tumor_sample_code
- maf_file
- tumor_grade
- primary_diagnosis
- histology_group
- grade_analysis
- histology_analysis

case_id	grado	diagnóstico / grupo	G2-G3	Histología
TCGA-2W-A8YY	G3	Adenosquamous carcinoma / Other	Sí	No
TCGA-4J-AA1J	G3	Squamous cell carcinoma, NOS / Squamous	Sí	Sí

El archivo final contiene 286 filas, una por paciente. Los indicadores grade_analysis e histology_analysis permiten incluir o excluir automáticamente cada caso de las comparaciones principales sin eliminarlo de la cohorte general.

Samplesheet del pipeline - Dataset B

patient_id	tumor_run	normal_run	tumor FASTQ	normal FASTQ
1094	ERR8314271	ERR8314261	R1 + R2	R1 + R2
755	ERR8314276	ERR8314265	R1 + R2	R1 + R2
999	ERR8314284	ERR8314269	R1 + R2	R1 + R2

Archivos incluidos en el repositorio:

- samplesheet/tcga_cesc_samplesheet.csv - cohorte principal.
- samplesheet/tcga_cesc_clinical_clean.csv - clínica consolidada.
- samplesheet/gdc_original_samplesheet.tsv - archivo original GDC.
- samplesheet/cervical_wes_pipeline_samplesheet.csv - pares tumor-normal y FASTQ.

Reproducibilidad: los archivos pesados (FASTQ y MAF) no se almacenan en GitHub. Se conservan manifests, metadata, samplesheets y URLs de descarga para reconstruir los datos.

5. Repositorio inicial y desarrollo parcial en Nextflow

El repositorio inicial ya contiene README, enlaces a los datasets, samplesheets, metadata, manifest, configuración y un main.nf mínimo funcional.

Repositorio GitHub

https://github.com/5leyla5/proyecto_cesc

Desarrollo parcial implementado

```
nextflow.enable.dsl=2

params.samplesheet = "samplesheet/cervical_wes_pipeline_samplesheet.csv"
params.outdir     = "results"

process FASTQC {
   tag "${patient_id}_${sample_type}"
   publishDir "${params.outdir}/qc", mode: 'copy'
   input:
   tuple val(patient_id), val(sample_type), path(read1), path(read2)
   output:
   path "*_fastqc.html", emit: html
   path "*_fastqc.zip", emit: zip
   script:
   """
   fastqc --threads 2 ${read1} ${read2}
   """
}
```

Validación inicial

El workflow se probó mediante ejecución simulada para validar lectura del samplesheet, construcción del canal y generación de seis tareas FastQC (3 tumores + 3 normales):

```
nextflow run main.nf -stub-run

executor > local (6)
FASTQC (1094_normal) | 6 of 6 ✔
```