Caracterización reproducible del paisaje mutacional del cáncer cervicouterino

Proyecto 2: Variantes somáticas, genes drivers y firmas mutacionales en cáncer

Pregunta biomédica: ¿Qué diferencias presenta el paisaje mutacional del cáncer cervicouterino según el grado tumoral (G2 vs G3) y el subtipo histológico (carcinoma escamoso vs adenocarcinoma), en términos de carga mutacional y genes recurrentemente alterados?

1. Contexto y propósito

El proyecto combina dos conjuntos de datos complementarios. El Dataset A se utiliza como rama técnica para demostrar un flujo reproducible desde FASTQ hasta variantes somáticas filtradas y anotadas. El Dataset B (TCGA-CESC) se utiliza como cohorte biológica para explorar diferencias en carga mutacional y genes recurrentemente alterados según grado tumoral e histología.

El objetivo de esta entrega es mostrar evidencia preliminar de calidad, reproducibilidad y análisis biológico, sin interpretar los subconjuntos de 1 millón de pares de lecturas del Dataset A como una estimación real de carga mutacional.

Componente	Dataset	N / alcance	Uso en Entrega 3
Rama técnica	Dataset A · E-MTAB-11407 / PRJEB50605	3 pares tumor-normal	QC, variantes PASS, anotación y trazabilidad del pipeline
Rama biológica	Dataset B · TCGA-CESC	286 pacientes únicos	Carga mutacional, genes recurrentes y oncoplots

Objetivo general

Caracterizar de forma reproducible el paisaje mutacional del cáncer cervicouterino mediante un workflow en Nextflow DSL2 para el procesamiento de variantes somáticas y un análisis de cohorte basado en datos públicos de TCGA-CESC.

Criterios analíticos principales

- Dataset A: control de calidad y validación técnica del pipeline.
- Dataset B: 1 MAF por paciente; se conservó el tumor primario cuando existía más de una muestra.
- Carga mutacional preliminar: número de mutaciones somáticas no sinónimas por tumor; no se reporta como TMB/Mb.
- Comparaciones clínicas: G2 vs G3 y carcinoma escamoso vs adenocarcinoma.
- Genes recurrentes: un gen se cuenta como mutado como máximo una vez por paciente.
- Pruebas estadísticas: Wilcoxon para carga mutacional y Fisher por gen, con corrección FDR de Benjamini-Hochberg.

2. Dataset A: Control de calidad técnico

El Dataset A corresponde a carcinoma escamoso cervicouterino con tres pares tumor-normal. Para la validación local se utilizaron subconjuntos reproducibles de 1 millón de pares de lecturas por muestra. El flujo incluye FastQC, BWA-MEM2, SAMtools, MarkDuplicates, Mutect2, FilterMutectCalls y SnpEff.

2.1 Alineamiento

Paciente	Muestra	% mapeado	% properly paired	% duplicación
1094	Normal	99,34	96,42	55,23
1094	Tumor	99,47	97,94	17,61
755	Normal	96,09	93,01	0,37
755	Tumor	98,84	94,46	1,33
999	Normal	99,77	97,96	0,24
999	Tumor	99,87	98,00	0,21

Las seis muestras presentaron altos porcentajes de alineamiento (96,09%–99,87%) y de lecturas correctamente pareadas (93,01%–98,00%). La principal diferencia de calidad se observó en la duplicación, particularmente en 1094_N (55,23%) y, en menor medida, 1094_T (17,61%). Esto sugiere menor complejidad efectiva de biblioteca en ese paciente y debe considerarse al interpretar sus llamadas de variantes.

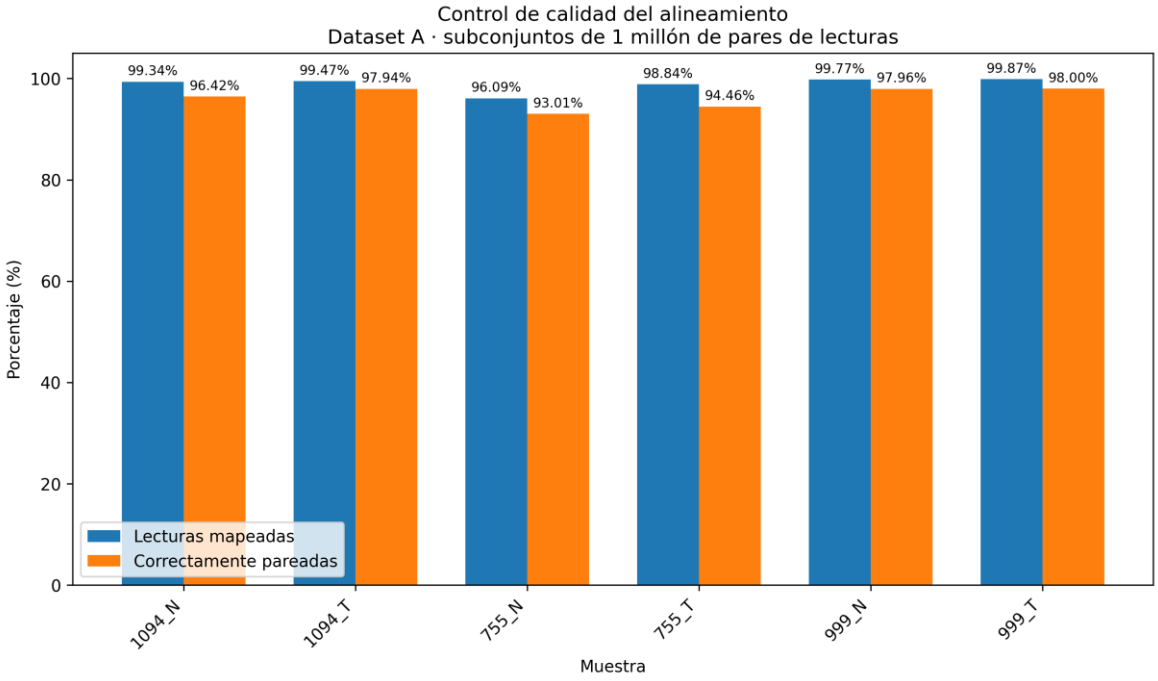


Figura 1. QC de alineamiento del Dataset A. Se muestran porcentajes de lecturas mapeadas y correctamente pareadas.

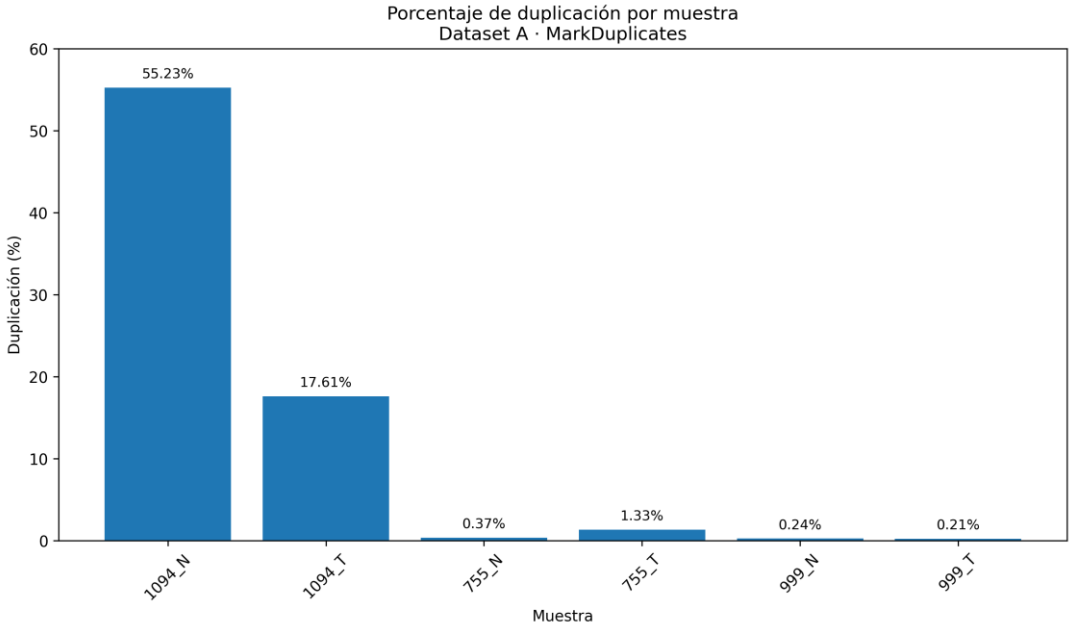


Figura 2. Porcentaje de duplicación por muestra. Destaca la duplicación elevada en 1094_N.

2.2 Variantes somáticas y filtrado

Paciente	Candidatas Mutect2	PASS	% PASS	SnpEff PASS
1094	46	6	13,04	6
755	27	15	55,56	15
999	482	34	7,05	34
Total	555	55	9,91	55

FilterMutectCalls conserva los registros y asigna un estado en la columna FILTER; por ello, el número de registros del VCF filtrado puede ser igual al de candidatas, mientras que el subconjunto PASS representa las llamadas que superaron los filtros. El paciente 999 presentó muchas más candidatas, pero solo 34 PASS. Este resultado no debe interpretarse como una carga mutacional real, ya que el Dataset A corresponde a submuestreos de 1M.

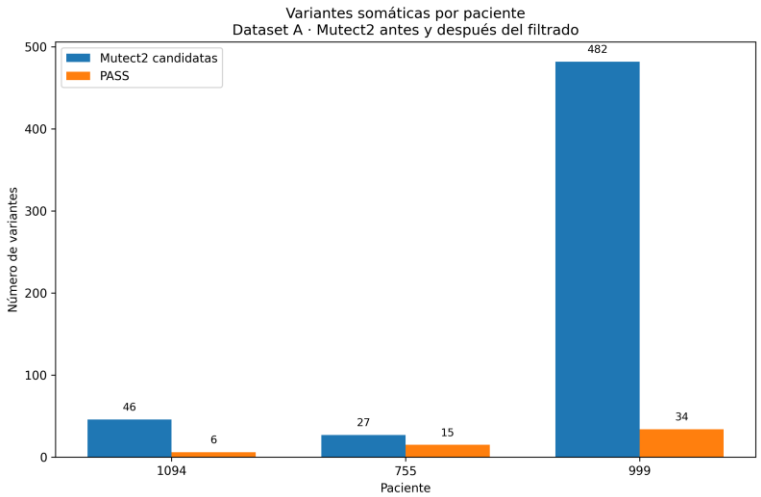


Figura 3. Variantes candidatas de Mutect2 y variantes PASS por paciente.

Interpretación del Dataset A

El Dataset A cumple el objetivo de demostrar un pipeline reproducible y generar evidencia de QC. Las 55 variantes PASS y sus anotaciones se consideran evidencia técnica preliminar, no validación clínica ni estimación de TMB.

3. Dataset B: Definición de la cohorte TCGA-CESC

Se descargaron 287 archivos MAF. Al mapear cada MAF a su identificador TCGA se identificaron 286 pacientes únicos. El paciente TCGA-UC-A7PG presentaba dos muestras tumorales: 01A (tumor primario) y 06A (metástasis). Para evitar doble conteo se conservó 01A y se excluyó 06A del análisis.

Variable	Categoría	N
Grado tumoral	G2	126
Grado tumoral	G3	111
Grado tumoral	GX / G1 / G4 / vacío	49
Histología	Squamous	236
Histología	Adenocarcinoma	46
Histología	Other	4

Las comparaciones por grado utilizaron 237 pacientes (126 G2 y 111 G3). Las comparaciones histológicas utilizaron 282 pacientes (236 escamosos y 46 adenocarcinomas). Los oncoplots se generaron con esas mismas cohortes para mantener consistencia

4. Carga mutacional preliminar

La carga mutacional se definió como el número de mutaciones somáticas no sinónimas por tumor. Se incluyeron las categorías Missense_Mutation, Nonsense_Mutation, Frame_Shift_Del, Frame_Shift_Ins, Splice_Site, In_Frame_Del, In_Frame_Ins, Nonstop_Mutation y Translation_Start_Site.

En los 286 tumores se contabilizaron 49.458 mutaciones no sinónimas. El rango fue amplio (1–9.867 por tumor), con presencia de casos hipermutados. En particular, TCGA-2W-A8YY (G3, histología Other) presentó 9.867 mutaciones no sinónimas, por lo que la mediana y una prueba no paramétrica resultan más adecuadas que el promedio para comparar grupos.

Comparación	Grupo	N	Mediana	Q1	Q3	Wilcoxon p
Grado	G2	126	69	48,2	118	0,808
Grado	G3	111	75	41	137	0,808
Histología	Escamoso	236	74	49	134	0,0686
Histología	Adenocarcinoma	46	63	37,8	122	0,0686

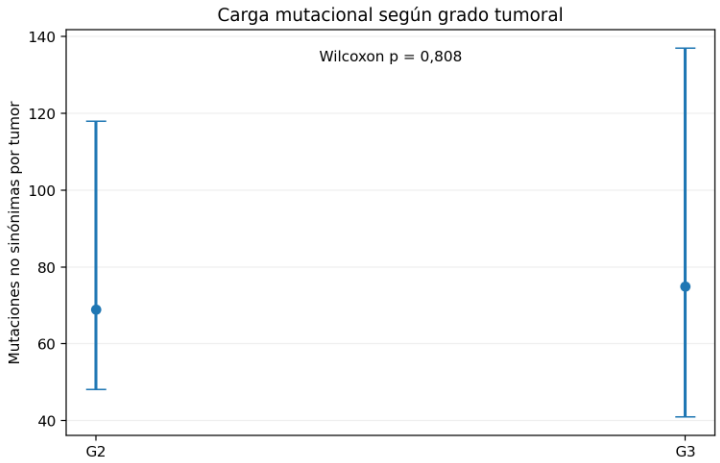


Figura 4. Mediana e intervalo intercuartílico de carga mutacional en G2 vs G3. No se observó diferencia significativa.

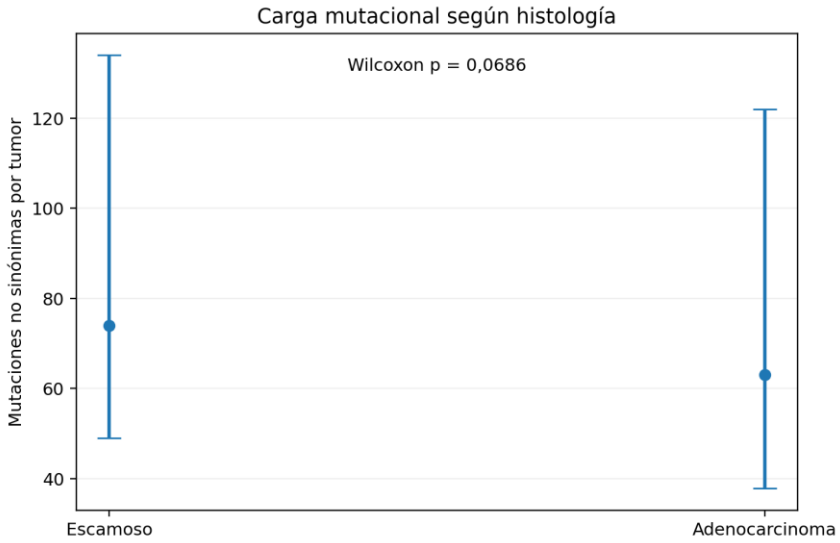


Figura 5. Mediana e intervalo intercuartílico según histología. Se observó una tendencia, sin alcanzar significancia estadística.

No se observaron diferencias significativas entre G2 y G3 (Wilcoxon p = 0,808). Para histología, los carcinomas escamosos presentaron una mediana mayor que los adenocarcinomas (74 vs 63), pero la diferencia no alcanzó significancia convencional (p = 0,0686); por tanto, se interpreta como una tendencia exploratoria.

5. Genes recurrentemente alterados

Para estimar recurrencia, cada gen se contó una sola vez por paciente aunque existieran múltiples variantes en el mismo gen. Los genes con mayor frecuencia global fueron TTN, PIK3CA, KMT2C y MUC16.

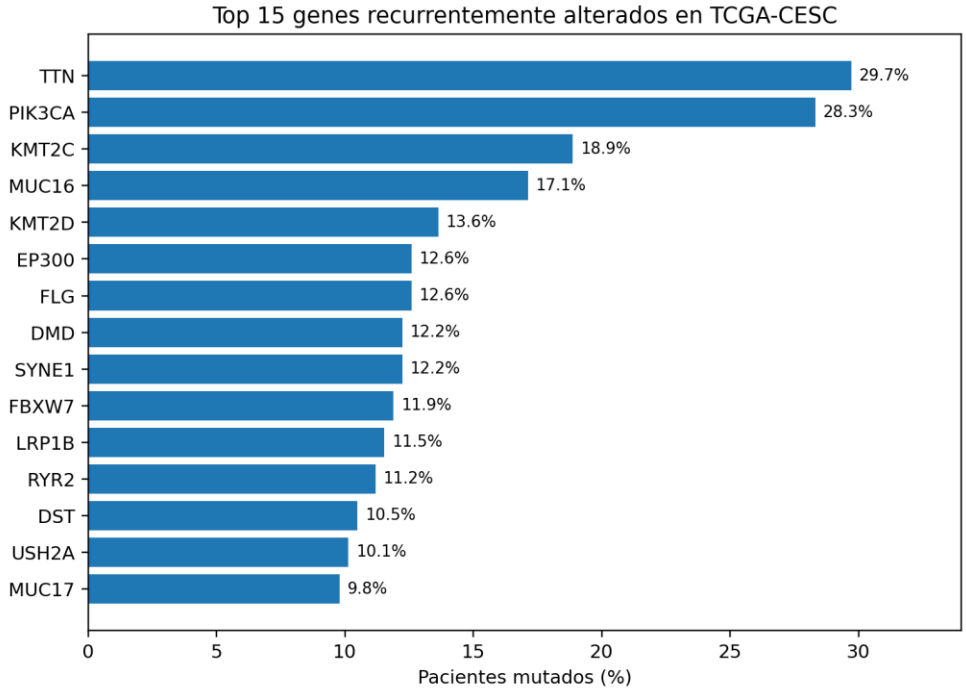


Figura 6. Top 15 genes recurrentemente alterados en los 286 pacientes TCGA-CESC.

Gen	Pacientes mutados	Frecuencia
TTN	85/286	29,72%
PIK3CA	81/286	28,32%
KMT2C	54/286	18,88%
MUC16	49/286	17,13%
KMT2D	39/286	13,64%
EP300	36/286	12,59%
FBXW7	34/286	11,89%

Genes de gran tamaño como TTN o MUC16 pueden acumular mutaciones con mayor frecuencia por su longitud; por ello, recurrencia no equivale automáticamente a condición de gen driver. PIK3CA, KMT2C, KMT2D, EP300 y FBXW7 son ejemplos especialmente relevantes para la interpretación biológica posterior.

5.1 Comparación G2 vs G3

Se aplicó prueba exacta de Fisher por gen y corrección de Benjamini-Hochberg. Los menores p-valores nominales se observaron en MYO18B, F5 y ARPP21 (0% en G2 vs 6,31% en G3; p = 0,00446), y en MDN1 (2,38% en G2 vs 11,7% en G3; p = 0,00753). Sin embargo, todos los resultados mostraron FDR = 1 en el análisis realizado. Por lo tanto, no se identificaron genes con diferencia robusta entre G2 y G3 tras corrección por comparaciones múltiples.

5.2 Comparación escamoso vs adenocarcinoma

Gen	Escamoso %	Adenocarcinoma %	p nominal	FDR
KRAS	2,54	19,6	$9{,}21\times10^{-5}$	1
TP53	4,24	17,4	0,00339	1
ERBB2	2,97	13,0	0,00959	1
TP73	1,27	10,9	0,00361	1

KRAS, TP53 y ERBB2 mostraron diferencias nominales llamativas, con mayor frecuencia en adenocarcinoma, pero ninguna asociación permaneció significativa tras corrección FDR. Estos hallazgos se presentan como exploratorios y no como diferencias confirmadas.

6. Oncoplots preliminares

Se generaron oncoplots con los 15 genes más recurrentes, clasificando las variantes no sinónimas en categorías funcionales. Para histología se incluyeron 282 pacientes (236 escamosos y 46 adenocarcinomas). Para grado se regeneró una tabla independiente que incluye los 237 pacientes G2/G3 completos (126 G2 y 111 G3), evitando excluir los cuatro casos de histología Other.

Figura generada	Cohorte	Archivo en repositorio
Oncoplot por histología	282 pacientes	results/tcga/figures/tcga_oncoplot_top15_histology.png
Oncoplot por grado	237 pacientes	results/tcga/figures/tcga_oncoplot_top15_G2_vs_G3.png

Nota de reproducibilidad
Los oncoplots se generan desde scripts independientes para histología y grado. Esto asegura que cada figura represente la cohorte elegible completa para la comparación correspondiente.

7. Concordancia exploratoria entre Dataset A y TCGA-CESC escamoso

Como análisis complementario se compararon los genes identificados en variantes PASS del Dataset A —que corresponde a carcinoma escamoso cervicouterino— con el subconjunto escamoso de TCGA-CESC (n = 236).

Comparación	Coincidencias	Proporción
Todos los genes asociados a variantes PASS de A	38/52	73,1%
Genes HIGH/MODERATE de A	17/19	89,5%

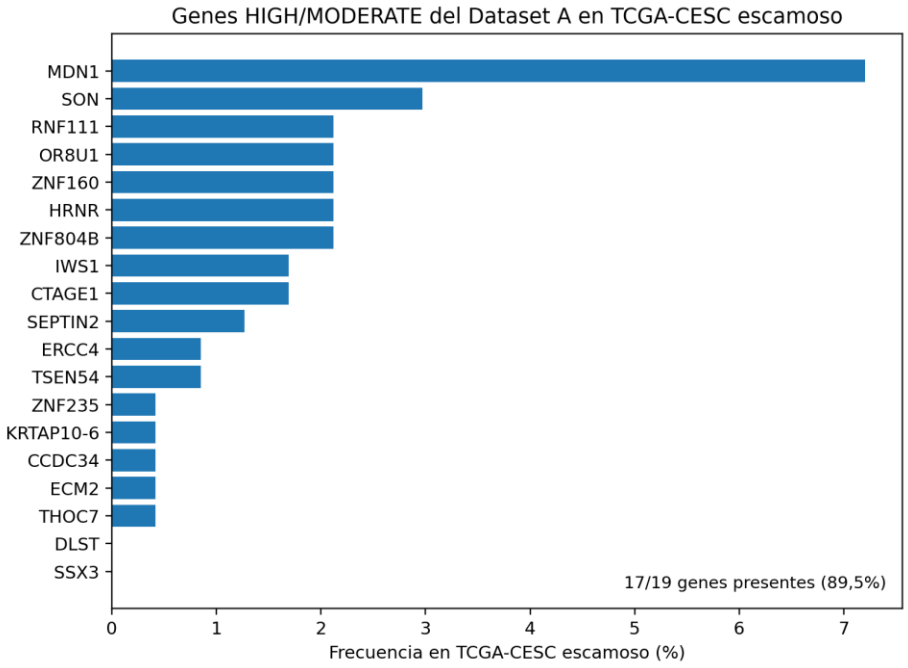


Figura 7. Frecuencia en TCGA-CESC escamoso de los genes HIGH/MODERATE identificados en el Dataset A.

MDN1 fue la coincidencia funcional más frecuente (17/236; 7,2%), seguida de SON (2,97%), HRNR, ZNF804B, OR8U1, RNF111 y ZNF160 (2,12% cada uno). Esta concordancia apoya la comparabilidad del flujo a nivel de gen, pero no constituye validación independiente de las variantes, ya que el Dataset A tiene solo tres pacientes y no se comparó necesariamente la misma posición o alelo.

8. Interpretación preliminar

- La calidad de alineamiento del Dataset A fue alta; la principal señal de QC fue la duplicación elevada en 1094_N.
- El pipeline técnico produjo 555 candidatas Mutect2 y 55 variantes PASS en los tres subconjuntos 1M.
- En TCGA-CESC no se observó diferencia significativa en carga mutacional entre G2 y G3.
- La comparación escamoso vs adenocarcinoma mostró una tendencia hacia mayor carga en escamoso, sin significancia estadística.
- PIK3CA se ubicó entre los genes más recurrentes de la cohorte, junto con TTN, KMT2C y MUC16.
- Las diferencias nominales de KRAS, TP53 y ERBB2 por histología no sobrevivieron la corrección FDR.
- La comparación A vs B mostró alta concordancia descriptiva a nivel de gen, especialmente para los genes HIGH/MODERATE de A.

Respuesta preliminar a la pregunta biomédica

Con los análisis realizados hasta esta entrega no se observa una diferencia estadísticamente significativa en la carga mutacional entre G2 y G3 ni entre carcinoma escamoso y adenocarcinoma. El paisaje de genes recurrentes sí muestra señales nominales distintas entre subtipos, especialmente en KRAS, TP53 y ERBB2, pero estas asociaciones no permanecen significativas después de corregir por comparaciones múltiples.

9. Limitaciones

- Los resultados del Dataset A provienen de submuestreos de 1M y no deben interpretarse como carga mutacional real.
- La rama Mutect2 técnica no incorpora todavía todos los recursos recomendados para una llamada clínica completa (por ejemplo, panel of normals, recurso poblacional germinal y estimación de contaminación).
- La carga mutacional del Dataset B se expresa como conteo de mutaciones no sinónimas por tumor y no como mutaciones/Mb.
- La comparación histológica es desbalanceada (236 escamosos vs 46 adenocarcinomas).
- Existen tumores hipermutados que influyen en los promedios; se priorizaron medianas y pruebas no paramétricas.
- El análisis por gen implica muchas comparaciones; por ello, los p-valores nominales deben interpretarse junto al FDR.
- La concordancia Dataset A vs B se evaluó a nivel de símbolo génico, no como validación de variantes exactas.

10. Reproducibilidad y organización del proyecto

La Entrega 3 incorporó scripts numerados y resultados livianos versionables. Los datos crudos y archivos grandes permanecen excluidos mediante .gitignore.

Bloque	Scripts principales
QC Dataset A	analysis/01_qc_datasetA.R · analysis/02_variant_qc_datasetA.R
Preparación TCGA	analysis/03_check_tcga_maf.py · analysis/04_tcga_mutation_burden.py
Estadística burden	analysis/05_tcga_mutation_burden_stats.R
Genes recurrentes	analysis/06_tcga_recurrent_genes.py · analysis/07_tcga_recurrent_genes_stats.R
Comparación A vs B	analysis/08_compare_datasetA_vs_tcga_squamous.py · analysis/09_datasetA_vs_tcga_squamous_plot.R
Oncoplots	analysis/10_tcga_oncoplot_data.py · 10b_tcga_oncoplot_grade_data.py · 11_tcga_oncoplot.R · 12_tcga_oncoplot_grade.R

Repositorio del proyecto: https://github.com/5leyla5/proyecto_cesc

Los resultados resumidos se almacenan en results/qc/ y results/tcga/, mientras que los archivos pesados (FASTQ, BAM, MAF crudos, work/ y referencias) no se versionan.

11. Próximos pasos para la entrega final

- Completar caracterización de sustituciones (Ti/Tv y contexto trinucleotídico).
- Explorar firmas mutacionales y su relación con subgrupos clínicos, si la calidad y el tipo de datos lo permiten.
- Profundizar interpretación de genes recurrentes y posibles drivers con evidencia externa.
- Refinar visualizaciones finales y seleccionar las figuras más informativas.
- Mantener trazabilidad entre scripts, tablas derivadas, figuras y conclusiones.

Conclusión

La Entrega 3 consolida las dos ramas del proyecto: el Dataset A demuestra un procesamiento reproducible con métricas de QC y variantes filtradas, mientras que TCGA-CESC permite realizar las primeras comparaciones biológicas de cohorte. Los resultados preliminares no evidencian diferencias significativas en carga mutacional por grado o histología, aunque se observan patrones exploratorios en genes recurrentes que justifican continuar la caracterización del paisaje mutacional en la etapa final.